

Laporan Teknis Komprehensif

“ITCareerMatch”

AI Career Matching & Skill Gap Analysis Platform



Oleh:
Tim CC26-PSU088 – Data Scientist

Coding Camp Powered by DBS Foundation
2026

DAFTAR ISI

DAFTAR ISI.....	i
DAFTAR TABEL.....	iii
DAFTAR GAMBAR.....	iv
BAB 1 PROBLEM DISCOVERY.....	1
1.1 Latar Belakang.....	1
1.2 Identifikasi Masalah.....	2
1.3 Gap Solusi yang Ada	2
BAB 2 TUJUAN PROYEK & DESAIN SOLUSI.....	4
2.1 Tujuan Utama.....	4
2.2 Kriteria Keberhasilan Data	4
2.3 Desain Skema Matching	5
2.4 Kamus Skill IT	5
BAB 3 PENGUMPULAN DATA.....	6
3.1 Sumber Data CV	6
3.2 Sumber Data Lowongan	6
3.3 Scraping Data Glints	9
BAB 4 PIPELINE CLEANING.....	11
4.1 Pipeline Cleaning Dataset CV	11
4.1.1 Deteksi Otomatis Jenis PDF	11
4.1.2 Segmentasi Teks CV ke Empat Seksi.....	12
4.1.3 Standarisasi Pendidikan dari Teks CV.....	13
4.1.4 Ekstraksi Skill dari Teks CV.....	13
4.1.5 Standarisasi Pengalaman dari Teks CV	14
4.1.6 Enrichment Kolom Detail via Groq API	15
4.1.7 Cleaning Output LLM.....	18
4.1.8 Deduplikasi dan Output Final Dataset CV.....	18
4.2 Pipeline Cleaning Dataset Job	19
4.2.1 Pembacaan Dataset	19
4.2.2 Mapping Kolom	20
4.2.3 Cleaning Dataset Scraping (Dataset untuk DB Fullstack).....	21
4.2.4 Cleaning Dataset Kaggle (AI Training Data)	23
4.2.5 Standarisasi Kolom Pendidikan	24
4.2.6 Standarisasi Kolom Pengalaman.....	25
4.2.7 Standarisasi Skill via Kamus IT	25
4.2.8 Enrichment Kolom Kualifikasi via Groq API	26
4.2.9 Deduplikasi Dataset Job.....	27
BAB 5 HASIL AKHIR DATASET & EDA	28
5.1 Dataset Bersih	28

5.2 Exploratory Data Analysis (EDA).....	29
BAB 6 KESIMPULAN.....	35
6.1 Pencapaian Teknis	35
6.2 Keterbatasan yang Teridentifikasi	35
BAB 7 REKOMENDASI & ACTION ITEMS	37
7.1 Prioritas Tinggi	37
7.2 Prioritas Sedang	37
7.3 Prioritas Jangka Panjang	38
REFERENSI	39
LAMPIRAN.....	40

DAFTAR TABEL

Tabel 1. Rincian Dataset	4
Tabel 2. Skema Matching	5
Tabel 3. Sumber Data CV	6
Tabel 4. Sumber Data Lowongan/Job	6
Tabel 5. Detail Penggunaan Deteksi Otomatis PDF	11
Tabel 6. Detail Segmentasi Teks CV	12
Tabel 7. Strategi Standarisasi Pengalaman	14
Tabel 8. Bucket Kategori Pengalaman	14
Tabel 9. Cleaning Lanjutan Hasil LLM	18
Tabel 10. Alur Cleaning Hasil Data Scraping	21
Tabel 11. Alur Cleaning Data Job Kaggle	23
Tabel 12. Klafisikasi Label Standarisasi Pendidikan	24
Tabel 13. Klasifikasi Standarisasi Pengalaman	25
Tabel 14. Detail Hasil Akhir Dataset/Data Bersih	28
Tabel 15. Ringkasan Pencapaian Teknis Data	35
Tabel 16. Ringkasan Keterbatasan Teknis Data	36

DAFTAR GAMBAR

Gambar 1. Visualisasi Business Question 1	29
Gambar 2. Visualisasi Business Question 2	29
Gambar 3. Visualisasi Business Question 3	30
Gambar 4. Visualisasi Business Question 4	30
Gambar 5. Visualisasi Business Question 5	31
Gambar 6. Visualisasi Business Question 6	31
Gambar 7. Visualisasi Business Question 7	32
Gambar 8. Visualisasi Business Question 8	32
Gambar 9. Visualisasi Business Question 9	33
Gambar 10. Visualisasi Business Question 10	34

BAB 1

PROBLEM DISCOVERY

1.1 Latar Belakang

Pertumbuhan ekonomi digital Indonesia berlangsung dengan laju yang luar biasa. Berdasarkan laporan e-Conomy SEA, ekonomi digital Indonesia mencapai USD 90 miliar pada 2024 dan diproyeksikan melampaui USD 330 miliar pada 2030, menjadikannya yang terbesar di Asia Tenggara. [1]

Di balik pertumbuhan ini terdapat persoalan tenaga kerja yang belum terselesaikan. Gayatri, Jaya, dan Rumata (2022) dalam penelitian yang dipublikasikan di jurnal Sustainability (MDPI) menggunakan analisis Bayesian terhadap data BPS 2018 dan proyeksi ILO 2020 menemukan bahwa supply tenaga kerja digital Indonesia pada 2021–2025 justru diproyeksikan melebihi demand, dengan surplus rata-rata 30.300 pekerja per tahun. Namun para peneliti menegaskan bahwa ini bukan kabar baik, surplus tersebut hanya menjadi masalah baru apabila tenaga kerja yang tersedia tidak memiliki kompetensi yang dibutuhkan industri. Dalam artikel yang sama, disebutkan proyeksi dari laporan World Bank (2018) bahwa Indonesia berpotensi menghadapi kekurangan 9 juta pekerja TIK terampil dan semi-terampil antara 2015–2030, setara sekitar 600 ribu per tahun, angka yang menggambarkan betapa besarnya kesenjangan kualitas, bukan kuantitas. [2]

Dampaknya paling dirasakan oleh fresh graduate IT. Azzahra et al. (2024) dalam penelitian yang dipublikasikan di Journal Transnational Universal Studies mencatat bahwa hanya 53% lulusan perguruan tinggi bekerja sesuai bidang studinya, sementara 40% pengusaha merasa fresh graduate tidak memiliki kompetensi yang dibutuhkan. [3] Permasalahan ini diperparah oleh keterbatasan platform yang tersedia. Platform seperti Glints menyediakan ribuan lowongan IT, namun tidak dilengkapi fitur yang dapat mengukur kesesuaian profil pelamar secara kuantitatif. Riset Populix dan KitaLulus (2024) menunjukkan bahwa sekitar 46% perusahaan di Indonesia kesulitan menemukan kandidat yang sesuai, bukan karena kekurangan pelamar, melainkan karena kesenjangan kualifikasi dan skill. [4] Kandidat tidak memiliki acuan yang jelas untuk mengetahui posisi mana yang paling sesuai dengan profil mereka, skill apa yang perlu dikembangkan, atau bagian CV mana yang masih lemah.

Berdasarkan permasalahan tersebut, tim mengembangkan ITCareerMatch sebagai solusi. Pengguna cukup mengunggah atau menginput CV mereka, lalu sistem mengekstraksi skill secara otomatis, menghitung skor kecocokan dengan berbagai posisi IT dalam bentuk persentase, dan menampilkan skill gap per posisi lengkap dengan tautan langsung ke lowongan di Glints. Proyek ini sejalan dengan SDG ke-8 tentang Pekerjaan Layak dan Pertumbuhan Ekonomi, untuk mendorong akses yang lebih adil dan efisien terhadap kesempatan kerja melalui pemanfaatan teknologi digital.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan di atas, terdapat beberapa gap yang menjadi inti permasalahan yang ingin diselesaikan oleh proyek ITCareerMatch. Gap-gap tersebut dapat dirumuskan dalam permasalahan berikut:

1. Minimnya platform yang memberikan rekomendasi pekerjaan IT yang benar-benar dipersonalisasi berdasarkan profil teknis pengguna. Kebanyakan sistem rekomendasi yang ada masih bekerja secara generik berdasarkan kata kunci atau industri, bukan berdasarkan analisis mendalam terhadap keterampilan aktual yang tercantum dalam CV. sehingga hasil rekomendasi sering kali tidak relevan dengan kompetensi riil pengguna.
2. Tidak adanya mekanisme umpan balik yang terukur antara profil CV kandidat dengan persyaratan lowongan IT yang spesifik. Platform pencarian kerja yang ada umumnya tidak memberikan informasi kuantitatif mengenai tingkat kesesuaian (*match score*) antara profil pengguna dengan posisi yang dilamar, sehingga kandidat tidak memiliki referensi yang objektif untuk mengevaluasi kelayakan mereka.
3. Kurangnya visibilitas terhadap skill gap yang dimiliki oleh kandidat. Sebagian besar pencari kerja IT tidak mengetahui secara spesifik keterampilan teknis apa yang belum mereka miliki namun dibutuhkan untuk posisi yang dituju. Tanpa informasi ini, upaya pengembangan diri menjadi tidak terarah dan tidak efisien.

1.3 Gap Solusi yang Ada

Platform *job board* yang ada di pasar saat ini (seperti LinkedIn, Jobstreet, dan Glints) berfungsi sebagai media transmisi informasi statis antara pemberi kerja dan pencari kerja, tempat perusahaan memposting lowongan dan kandidat melamar secara mandiri. Platform-platform ini tidak melakukan analisis kecocokan antara profil kandidat dengan persyaratan lowongan. [5] Sehingga platform tersebut memiliki keterbatasan, seperti:

- Platform umumnya berfungsi hanya sebagai tempat penyimpanan (*repositori*) iklan lowongan. Mekanisme pencarian yang tersedia lebih mengandalkan *keyword-based search* dasar dan tidak mampu melakukan analisis terhadap isi CV pelamar secara otomatis dan presisi.
- Sebagian besar CV berbentuk dokumen (PDF) dengan format bebas, platform konvensional tidak melakukan ekstraksi dan pemrosesan data tidak terstruktur. Akibatnya, proses penulisan kandidat yang relevan sepenuhnya bergantung pada proses manual rekruter atau pencarian kata kunci sederhana.
- Platform yang ada saat ini bersifat searah (*one-way*). Tidak tersedia wadah diskusi yang terintegrasi di dalam aplikasi yang memungkinkan pencari kerja untuk bertukar pikiran, bertanya detail mengenai sebuah lowongan, atau melakukan *brainstorming* terkait persiapan karier secara *real-time*.

ITCareerMatch hadir sebagai solusi dengan menggunakan teknologi yang mampu memahami makna dan konteks dari keahlian seseorang, bukan sekadar mencocokkan kata

kunci secara mentah. Sistem ini mengenali hubungan antar skill (seperti keterkaitan antara bahasa pemrograman dengan framework atau bidang kerja tertentu), serta menyediakan fitur diskusi agar pengguna dapat berinteraksi dan bertukar informasi secara aktif.

BAB 2

TUJUAN PROYEK & DESAIN SOLUSI

2.1 Tujuan Utama

Mengembangkan infrastruktur data yang terstruktur dan berkualitas sebagai fondasi utama bagi model *job-CV matching* berbasis AI. Fokus utama proyek ini adalah melakukan transformasi data mentah dari berbagai sumber menjadi *dataset* yang siap pakai untuk analisis semantik, dengan rincian sebagai berikut:

Tabel 1. Rincian Dataset

Output	Deskripsi	Ukuran Final Dataset
dataset_cv	Profil kandidat IT yang telah distandarisasi. Berisi pendidikan, pengalaman, skill, dan ringkasan profil kandidat. Digunakan sebagai sisi kandidat dalam sistem job-CV matching.	11.915 baris $\times$ 4 kolom
dataset_job	Data lowongan kerja IT gabungan yang berisi persyaratan posisi yang sudah dinormalisasi. Digunakan sebagai dataset utama untuk sisi job dalam sistem matching.	11.027 baris $\times$ 9 kolom
glints_job	Data referensi tren pasar job IT di Indonesia dari Glints dengan data lengkap (termasuk URL, perusahaan, gaji, sistem kerja). Digunakan untuk basis data fullstack dan sebagai data asli dan direct ke platform glints.	565 baris $\times$ 14 kolom

2.2 Kriteria Keberhasilan Data

Untuk menjamin dataset memiliki daya prediktif yang akurat dalam sistem *matching*, kami menetapkan standar kualitas data yang ketat sebagai berikut:

- **Konsistensi Format**
Seluruh atribut kunci seperti pendidikan, pengalaman, dan *skill* menggunakan skema kategori yang seragam di seluruh sumber dataset.
- **Normalisasi Skill**
Setiap entitas *skill* telah dipetakan ke dalam format nama formal menggunakan kamus referensi industri IT yang terkurasi.

- Kelengkapan Narasi
Kolom detail pada CV dan kualifikasi pada *Job* dipastikan memiliki tingkat pengisian $\geq 90\%$ melalui ekstraksi berbasis *Large Language Model* (LLM).
- Minimalisasi Noise
Melakukan pembersihan data secara menyeluruh untuk menghapus entitas yang tidak relevan (baris tanpa *skill*) dan melakukan deduplikasi data berdasarkan profil kualifikasi.

2.3 Desain Skema Matching

Sistem matching dirancang berdasarkan empat dimensi kualifikasi sebagai jembatan antara sisi kandidat dan sisi lowongan:

Tabel 2. Skema Matching

Dimensi	dataset_cv (Kandidat)	Dataset_job (Lowongan)	Peran dalam Matching
Pendidikan	8 kategori standar	7 kategori standar	<i>Hard constraint filter</i>
Pengalaman	7 kategori baku	+106 variasi (perlu normalisasi)	Filter tingkat senioritas
Skill	CSV multi-skill ternormalisasi	CSV multi-skill ternormalisasi	<i>Jaccard / cosine similarity</i> berbasis set
Narasi	Kolom detail (LLM-generated)	Kolom kualifikasi (LLM-generated)	<i>Semantic embedding similarity</i>

2.4 Kamus Skill IT

Kami membangun dan menggunakan kamus skill IT terpilah (kamus_skill_cv.csv dan Kamus_IT_Bersih_Filtered.csv.) untuk menstandarisasi data pada pipeline CV maupun lowongan kerja. Kamus ini memetakan berbagai variasi penulisan (variasi) ke dalam satu nama standar (formal). Tanpa standarisasi ini, variasi penulisan seperti 'tensorflow', 'TF', dan 'tensor flow' akan terbaca sebagai entitas yang berbeda, sehingga akurasi sistem matching menjadi tidak valid.

BAB 3 PENGUMPULAN DATA

3.1 Sumber Data CV

Data CV dikumpulkan dari dua sumber, yakni CV berupa PDF yang selanjutnya masuk ke proses OCR dan CV teks resume panjang dalam kolom/tabel.

Tabel 3. Sumber Data CV

Sumber Data Mentah	Format/Jumlah Awal	Deskripsi	Karakteristik
Kaggle dataset https://www.kaggle.com/datasets/hadiikp/resume-data-pdf	PDF (teks & scan)/+-300 file	Dataset ini adalah kumpulan PDF resume/CV yang terdiri dari berbagai kategori role profesional	Beragam template visual, memerlukan OCR
Kaggle dataset https://www.kaggle.com/datasets/yaswanthkumary/ai-recruitment-pipeline-dataset	Excel/CSV/ 10.174 baris	Dataset ini berisi informasi tentang kandidat yang melamar berbagai peran. Data terdiri dari transkrip wawancara, resume, deskripsi pekerjaan, dan keputusan akhir perekrutan.	Teks resume panjang dalam satu kolom, bahasa Inggris

3.2 Sumber Data Lowongan

Data lowongan dikumpulkan dari delapan sumber berbeda untuk mengurangi bias sumber tunggal. [6] Diversifikasi ini menghasilkan cakupan posisi IT yang lebih luas dan lebih representatif terhadap kondisi pasar.

Tabel 4. Sumber Data Lowongan/Job

Sumber Data Mentah	Format/Jumlah Awal	Deskripsi	Karakteristik
Kaggle dataset https://www.kaggle.com/datasets/dhivy	Excel/CSV/ 493 baris	Dataset ini berisi informasi mengenai berbagai macam peran atau posisi pekerjaan	Terdiri dari kolom: Job Title, Job Description, Skills, Certification

Sumber Data Mentah	Format/Jumlah Awal	Deskripsi	Karakteristik
adharunaba/it-job-roles-skills-dataset		di bidang IT beserta kebutuhan keahlian spesifiknya. Data mencakup informasi mengenai nama posisi, keahlian wajib (<i>skills</i>), serta kualifikasi teknis yang dicari oleh industri	
Kaggle dataset https://www.kaggle.com/datasets/meerawks/it-skills-from-jobs	Excel/CSV/ 3000 baris	Dataset ini menyediakan kumpulan data lowongan pekerjaan sektor teknologi yang berfokus pada ekstraksi keahlian (<i>skills</i>) dari deskripsi pekerjaan. Data memuat informasi posisi, kebutuhan keahlian khusus, tingkat pengalaman, serta kualifikasi yang relevan	Terdiri dari kolom: ID, Query, Job Title, Description, IT Skills, Soft Skills, Education, Experience, Token Usage
Kaggle dataset https://www.kaggle.com/datasets/asaniczka/linkedin-data-engineer-job-postings	Excel/CSV/ 6025 baris	Dataset ini berisi ribuan data lowongan pekerjaan khusus untuk posisi Data Engineer yang dikumpulkan dari platform LinkedIn. Data memuat informasi komprehensif mulai dari nama posisi, deskripsi pekerjaan, syarat pengalaman, tingkat pendidikan, hingga kualifikasi utama	Terdiri dari kolom: job_title, company, job_location, job_link, first_seen, search_city, search_country, job_level, job_type, job_summary, job_skills
Kaggle dataset https://www.kaggle.com/datasets/saurav0507/it-job-opportunities-	Excel/CSV/ 364 baris	Dataset ini memuat data historis peluang lowongan kerja di bidang IT dari tahun 2019 hingga 2023. Informasi didalamnya	Terdiri dari kolom: Job Title, Job Description, Required Skills, Salary Range, Location, Company, Experience Level, Industry,

Sumber Data Mentah	Format/Jumlah Awal	Deskripsi	Karakteristik
dataset-2019-2023/data		mencakup tren posisi lowongan, kualifikasi yang diminta, syarat minimal pengalaman, tingkat pendidikan, serta informasi demografi pasar kerja terkait	Job Type, Date Posted
Huggingface dataset https://huggingface.co/datasets/NxtGenIntern/job_titles_and_descriptions	Excel/CSV/ 289 baris	Dataset ini menyediakan pasangan data antara judul posisi pekerjaan (<i>job titles</i>) dan deskripsi lengkap dari pekerjaan tersebut (<i>job descriptions</i>). Data ini memuat narasi kualifikasi, tanggung jawab, serta keahlian yang dibutuhkan untuk berbagai macam peran profesional	Terdiri dari kolom: Job Title, Skills, Job Description
Kaggle dataset https://www.kaggle.com/datasets/bishop36/jobs-data	Excel/CSV/ 2250 baris	Dataset ini berisi kumpulan informasi lowongan kerja umum yang mencakup detail rekrutmen perusahaan. Data di dalamnya memuat informasi mengenai nama posisi, syarat minimal pendidikan, pengalaman kerja, keahlian, kualifikasi, serta preferensi demografi seperti batasan usia atau gender jika dicantumkan	Terdiri dari kolom: Job Name, Company Name, JD, Skills, Date Posted, YOE, Location, Website, Job Function, Industry, Specialization, Qualification, Hiring Location, Role, Vacancies
Kaggle dataset https://www.kaggle.com/datasets/prabinraj/it-job-vacancies-and-requirements	Excel/CSV/ 353 baris	Dataset ini berisi informasi mengenai lowongan kerja aktif di bidang IT beserta daftar persyaratan (<i>requirements</i>) yang	Terdiri dari kolom: Job_title, company, location, skills_required

Sumber Data Mentah	Format/ Jumlah Awal	Deskripsi	Karakteristik
		ditetapkan oleh perusahaan. Data mencakup spesifikasi posisi, kebutuhan <i>skill</i> , syarat pengalaman kerja, tingkat pendidikan, dan kualifikasi pendukung lainnya	
Scraping Glints	Excel/ 565 baris	Dataset ini berisi data lowongan pekerjaan sektor IT di Indonesia yang diperoleh secara langsung melalui proses <i>web scraping</i> dari platform Glints	Terdiri dari kolom: tautan, posisi, perusahaan, lokasi, gaji, jenis_pekerjaan, kategori, pendidikan, pengalaman, gender, usia, skill, kualifikasi

3.3 Scraping Data Glints

Scraping dilakukan menggunakan Selenium WebDriver. Framework ini dipilih karena Glints adalah React SPA yang tidak dapat di-parse dengan library HTTP statis. [7] Arsitektur scraping dibagi dua stage untuk memisahkan tanggung jawab dan meningkatkan ketahanan terhadap error.

Stage 1 Kumpulkan URL & Lokasi

- `WebDriverWait(driver, 25)` : menunggu card lowongan muncul dengan timeout 25 detik, cukup untuk koneksi lambat.
- `scroll_down(steps=8, px=700)` : scroll halaman perlahan agar lazy-load card sempat termuat sebelum diekstrak.
- Hasil disimpan ke dictionary `unique_data` (key = URL) untuk deduplication otomatis selama pengumpulan.

Stage 2 Ekstrak 13 Atribut per URL

- Setiap URL dibuka dengan driver baru (`init_driver()` dipanggil ulang) untuk menghindari session leak antar request.
- Kolom gaji diekstrak via `execute_script('return arguments[0].innerText')` karena angka gaji tersimpan di text node yang tidak terbaca CSS selector biasa.
- Fallback selector disiapkan untuk setiap field, Glints kerap mengubah class CSS tanpa pemberitahuan.

Konfigurasi Anti-Bot Detection

- `--disable-blink-features=AutomationControlled` : hapus flag otomasi Chrome
- `excludeSwitches: ['enable-automation']` : sembunyikan banner otomasi
- `CDP Page.addScriptToEvaluateOnNewDocument` : override `navigator.webdriver = undefined`
- Custom User-Agent (Chrome/124.0.0.0) : tampak seperti browser biasa
- `DELAY = 2.0` detik antar aksi : simulasi perilaku manusia

Hasil scraping awal jauh lebih besar dari 565 baris, namun banyak data terduplikat meski URL berbeda, web mempromosikan lowongan yang sama di beberapa posisi halaman. Setelah `drop_duplicates(subset=['perusahaan', 'posisi'])`, tersisa 565 baris unik.

BAB 4

PIPELINE CLEANING

4.1 Pipeline Cleaning Dataset CV

Pipeline cleaning untuk dataset ini ada pada notebook `pipeline_cv_data_cleaning.ipynb` (dapat diakses pada tautan berikut https://github.com/ITCareerMatch/Data-Science-ITCareerMatch/blob/main/notebook/pipeline_cv_data_cleaning.ipynb) dengan hasil data clean `dataset_cv.xlsx` (dapat diakses melalui tautan berikut https://github.com/ITCareerMatch/Data-Science-ITCareerMatch/blob/main/dataset_clean/dataset_cv.xlsx). Alur pipeline cleaning secara detail terdiri dari beberapa tahapan berikut:

4.1.1 Deteksi Otomatis Jenis PDF

CV dalam format PDF terbagi dua jenis: teks-based (dibuat dari word processor) dan image-based (hasil scan atau foto). Keduanya memerlukan strategi ekstraksi berbeda dan deteksi otomatis. Deteksi otomatis diperlukan karena tidak praktis mengklasifikasikan ribuan file secara manual.

```
def is_pdf_image_based(pdf_path, sample_pages=2):
    total_chars = 0
    with pdfplumber.open(pdf_path) as pdf:
        for page in pdf.pages[:sample_pages]:
            text = page.extract_text(x_tolerance=2,
                                    y_tolerance=2)
            if text: total_chars += len(text.strip())
    return total_chars < (30 * sample_pages)
# Threshold 30 char/halaman: PDF teks-based → ratusan char
# PDF image-based → 0-beberapa char noise
```

Tabel 5. Detail Penggunaan Deteksi Otomatis PDF

Jenis PDF	Library	Parameter Kunci	Kapan Digunakan
PDF teks-based (digital)	pdfplumber	x_tolerance=2, y_tolerance=2	Char yang diekstrak ≥ 30 per halaman
PDF image-based (scan/foto)	pdf2image + pytesseract	DPI=300, lang='ind+eng'	Char yang diekstrak < 30 per halaman

DPI=300 dipilih karena merupakan standar minimum untuk OCR berkualitas tinggi, namun menghasilkan waktu proses yang sangat lama. DPI lebih rendah menghasilkan karakter buram, Language parameter ind+eng mendukung CV dalam Bahasa Indonesia dan Inggris.

4.1.2 Segmentasi Teks CV ke Empat Seksi

Teks di dalam CV diekstraksi menjadi empat bagian utama dengan cara membaca baris demi baris menggunakan pola tertentu (regex). Metode ini dipilih karena format CV sangat beragam dan tidak beraturan. Dengan mendeteksi baris pendek sebagai penanda judul seksi (seperti "Pengalaman", "Pendidikan", atau "Skill"), sistem menjadi jauh lebih stabil dan akurat dalam mengenali struktur CV dibandingkan metode lain yang mencoba membaca seluruh dokumen sekaligus.

```
header_mapping = {
    r'^(experience|work experience|pengalaman
kerja|...)': 'Pengalaman',
    r'^(education|academic background|pendidikan|...)':
'Pendidikan',
    r'^(skills|core competencies|keahlian|...)':
'Skills',
}
current_section = 'Lainnya' # default untuk baris tanpa
header match
```

Tabel 6. Detail Segmentasi Teks CV

Kolom	Header yang Dikenali	Konten yang Ditangkap
Pendidikan	education, academic background, pendidikan, riwayat pendidikan	Institusi, jurusan, tahun lulus
Pengalaman	work experience, employment history, pengalaman kerja, riwayat pekerjaan	Perusahaan, posisi, durasi, tanggung jawab
Skills	skills, core competencies, keahlian, kompetensi, technical skills	Skill teknis

Kolom	Header yang Dikenali	Konten yang Ditangkap
Lainnya	Semua baris di luar tiga seksi di atas	Ringkasan profil, sertifikasi, kontak

4.1.3 Standarisasi Pendidikan dari Teks CV

Teks kolom Pendidikan hasil OCR sangat beragam: 'Bachelor of Science in Computer Science', 'B.Sc (Hons)', 'S1 Teknik Informatika', 'undergraduate degree'. Fungsi `extract_education_level()` menggunakan hierarki regex multi-level dengan pencocokan top-down:

```
checks = [
    ([r'ph\.?d',
     r'doctor(?:ate|al)?\s+(?:of|in|degree)'], 'PhD (S3)'),
    ([r'm\.?s\.?c?\b', r'master(?:s|\'s)?\s+...'],
     'Magister (S2)'),
    ([r'b\.?s\.?c?\b', r'bachelor(?:s|\'s)?\s+...'],
     'Sarjana (S1)'),
    ([r'associate(?:s|\'s)?\s+(?:of|in|degree)'],
     'Diploma 3 (D3)'),
    ([r'high\s+school', r'secondary\s+school',
     r'ged\b'], 'SMA/SMK'),
]
```

Sistem menggunakan pendekatan top-down untuk menentukan tingkat pendidikan dari CV. Dalam metode ini, sistem melakukan pencarian berdasarkan jenjang pendidikan tertinggi terlebih dahulu. Misalnya, jika sebuah CV mengandung istilah 'PhD' sekaligus 'Bachelor', sistem akan mengategorikan kandidat tersebut sebagai lulusan PhD. Urutan prioritas ini memastikan bahwa kualifikasi pendidikan tidak tertukar dan tetap akurat sesuai dengan jenjang tertinggi yang dimiliki kandidat.

4.1.4 Ekstraksi Skill dari Teks CV

Skill diekstrak dari gabungan kolom Skills dan Pengalaman (bukan hanya Skills). Ini dilakukan karena kandidat sering menyebutkan skill dalam konteks pengalaman kerja (contohnya “Developed REST APIs using Django and PostgreSQL”) yang tidak muncul di bagian Skills.

```
def extract_skills(row, cols=('Skills', 'Pengalaman')) -
> list[str]:
    combined = ' '.join(str(row.get(c, '')) for c in
                           cols if pd.notna(row.get(c)))
```

```

found = set()
for pattern, formal in SKILL_PATTERNS: # diurutkan
    terpanjang → terpendek
    if pattern.search(combined):
        found.add(formal)
return sorted(found)

```

Baris dengan `Skills_Extracted = []` dihapus dari dataset. Keputusan ini diambil karena entri tersebut tidak memiliki informasi teknis yang memadai untuk diproses oleh sistem *matching* berbasis kemiripan keahlian (*skill similarity*). Penghapusan ini memastikan model hanya dilatih menggunakan data yang relevan dan informatif, sehingga meningkatkan kualitas prediksi sistem secara keseluruhan.

4.1.5 Standarisasi Pengalaman dari Teks CV

Berbeda dari dataset job yang memiliki kolom pengalaman tersendiri, pengalaman di CV harus diekstrak dari teks panjang. Dua strategi dijalankan secara berurutan:

Tabel 7. Strategi Standarisasi Pengalaman

Strategi	Mekanisme	Contoh
Eksplisit (prioritas 1)	Deteksi frasa langsung: '5+ years of experience', 'over 3 years'	'5+ years of experience in backend' → 5 tahun
Inferensi dari tahun (fallback)	Cari rentang tahun dalam teks, hitung selisih; 'present/current' = 2024	'2018–2023 Software Engineer' → 5 tahun → 3-5 tahun'

Setelah ekstraksi, nilai tahun dikategorikan ke tujuh bucket yang selaras dengan kategori pengalaman umum di job posting Indonesia:

Tabel 8. Bucket Kategori Pengalaman

Tahun	Label Kategori	Konteks Pasar Kerja
< 1	0-1 tahun	Fresh graduate / career switcher
1–2	1-2 tahun	Junior awal
2–3	2-3 tahun	Junior-Intermediate

Tahun	Label Kategori	Konteks Pasar Kerja
3–5	3-5 tahun	Mid-level
5–10	5-10 tahun	Senior
≥ 10	10+ tahun	Expert / Principal

4.1.6 Enrichment Kolom Detail via Groq API

Kolom Lainnya pada hasil segmentasi CV memuat informasi naratif seperti ringkasan profil, tujuan karier, dan deskripsi proyek. Karena data ini bersifat tidak terstruktur, bantuan LLM Groq (LLaMA-3.1-8b-Instant) digunakan untuk mengekstrak serta merangkumnya menjadi satu kalimat padat pada kolom detail. Proses ini bertujuan mengubah narasi bebas menjadi format terstandar, sehingga informasi tersebut dapat disandingkan secara objektif dengan kualifikasi pada data lowongan kerja.

Kemudian strategi untuk menghemat token, kami menggunakan fungsi `prefilter_resume()` untuk mengekstrak hanya bagian Summary atau Experience terlebih dahulu agar mengurangi token input sambil mempertahankan informasi paling relevan.

```
def prefilter_resume(resume_text: str) -> str:
    # Prioritas 1: cari seksi Summary/Profile
    for headers in (_SUMMARY_HEADERS,
                    _EXPERIENCE_HEADERS):
        snippet = _extract_section(text, headers)
        if snippet and len(snippet) >= MIN_INPUT_CHARS:
            return snippet
    # Fallback: ambil 2000 karakter pertama
    return text.strip()[:MAX_INPUT_CHARS]
```

Selain menggunakan strategi prefilter untuk menghemat token, kami juga menggunakan skema batch processing. Setiap `BATCH_SIZE = 20` baris selesai diproses, hasilnya langsung tersimpan di file checkpoint Excel. Jika notebook crash atau koneksi Groq API terputus di tengah jalan, proses dapat dilanjutkan dari baris terakhir yang tersimpan tanpa mengulang dari awal. Mekanisme kerja strategi ini dibagi menjadi 3 tahap, yakni:

1. Load Checkpoint

Saat notebook dijalankan, sistem memeriksa apakah file checkpoint sudah ada. Jika ada, `done_indices` dibangun dari kolom `original_index` di checkpoint berisi daftar index baris yang sudah selesai. `drop_duplicates`

dijalankan saat load untuk berjaga-jaga jika checkpoint mengandung entri ganda akibat crash di tengah penyimpanan batch sebelumnya.

```
CHECKPOINT =
'../checkpoint_LLM/detail_checkpoint_dataset_cv_ocr.xlsx'
BATCH_SIZE = 20

if os.path.exists(CHECKPOINT):
    ckpt = pd.read_excel(CHECKPOINT)
    ckpt =
    ckpt.drop_duplicates(subset='original_index',
    keep='last')
    done_indices =
    set(ckpt['original_index'].astype(int).tolist())
    print(f'Melanjutkan proses... sudah selesai:
    {len(done_indices):,} baris')
else:
    ckpt =
    pd.DataFrame(columns=['original_index', 'detail'])
    done_indices = set()
    print('Belum ada checkpoint, mulai dari awal.')

# Hanya proses baris yang belum ada di checkpoint
pending = [idx for idx in df_run.index if idx not in
done_indices]
```

2. Proses dengan Skip

Setiap baris di pending diperiksa terlebih dahulu: jika teksnya kosong atau di bawah MIN_INPUT_CHARS, baris tersebut di-skip (dicatat dengan detail = "") tanpa dikirim ke API. Ini mencegah pemborosan kuota Groq.

```
for count, idx in enumerate(pending, start=1):
    teks = df_run.loc[idx].get('Lainnya', '')

    # Skip baris dengan teks terlalu pendek
    if not pd.notna(teks) or len(str(teks).strip()) <
MIN_INPUT_CHARS:
        new_rows.append({'original_index': idx,
'detail': ''})
```

```

        n_skip += 1
        continue

    try:
        result = run_groq(teks) # kirim ke Groq API
        new_rows.append({'original_index': idx,
'detail': result})
    except Exception as e:
        new_rows.append({'original_index': idx,
'detail': ''})
        n_error += 1

    time.sleep(DELAY_BETWEEN_CALLS) # jaga rate limit

```

3. Simpan Checkpoint Setiap Batch

Setiap kali `new_rows` mencapai `BATCH_SIZE`, hasilnya langsung disimpan ke file checkpoint. `drop_duplicates` dijalankan lagi saat simpan sebagai lapisan perlindungan kedua — memastikan tidak ada index yang tercatat dua kali meski proses terhenti di tengah loop. Setelah sesi selesai, hasil checkpoint di-merge kembali ke DataFrame utama menggunakan `map()` berbasis index.

```

# Simpan setiap BATCH_SIZE baris
if len(new_rows) >= BATCH_SIZE:
    batch_df = pd.DataFrame(new_rows)
    ckpt = pd.concat([ckpt, batch_df],
ignore_index=True)
    ckpt =
ckpt.drop_duplicates(subset='original_index',
keep='last') # double protection
    ckpt.to_excel(CHECKPOINT, index=False)

done_indices.update(batch_df['original_index'].tolist(
))

    print(f' Checkpoint disimpan | Total saved:
{len(done_indices):,}')
    new_rows = [] # reset buffer

# Setelah loop selesai — gabungkan hasil ke DataFrame
utama

```

```

ckpt_indexed = (
    ckpt.drop_duplicates(subset='original_index',
        keep='last')
        .set_index('original_index')['detail']
)
df['detail'] =
df.index.to_series().map(ckpt_indexed).fillna('')

```

Skema yang sama diulang untuk dataset tambahan (resume teks Kaggle) dengan variabel checkpoint terpisah CHECKPOINT_TAMBAHAN, sehingga kedua proses dapat berjalan independen dan dilanjutkan kapan saja tanpa saling mengganggu.

4.1.7 Cleaning Output LLM

Setelah generasi LLM, output kolom detail masih mengandung tiga jenis noise yang perlu dibersihkan:

Tabel 9. Cleaning Lanjutan Hasil LLM

Jenis Noise	Pola Deteksi	Penanganan	Alasan
Frasa tidak-informatif	'tidak mengandung informasi', 'nul, nul, nul'	Dikosongkan ("")	Data kosong lebih baik dari data misleading
Kata pengantar	'Detail kandidat: ...', 'Pengalaman kerja: ...'	Strip prefix via PENGANTAR_RE	Prefix adalah artifact LLM, bukan konten substantif
Token NULL di tengah kalimat	'berpengalaman NULL tahun'	Ganti NULL → '0'	Mempertahankan struktur kalimat dengan nilai bermakna

4.1.8 Deduplikasi dan Output Final Dataset CV

Setelah dua sumber (CV PDF dan Resume teks Kaggle) digabung, deduplikasi dilakukan berdasarkan kolom skill. Dalam sistem matching, dua kandidat dengan skill yang persis sama menghasilkan rekomendasi yang sama, tidak ada nilai tambah mempertahankan keduanya. Dari setiap grup duplikat, dipertahankan baris dengan detail terpanjang.

```

df_gabung['_detail_len'] =
df_gabung['detail'].fillna('').str.len()

df_dedup = (
    df_gabung
        .sort_values('_detail_len', ascending=False)    #
        terpanjang di atas
        .drop_duplicates(subset=['skill'], keep='first') #
        ambil terpanjang
        .drop(columns=['_detail_len'])
        .reset_index(drop=True)
)

```

Kemudian setelah tersimpan, dataset final hasil pipeline otomatis melalui pemeriksaan manual untuk memastikan kualitas data menyeluruh, terutama pada narasi kolom detail hasil generate LLM, hasil normalisasi skill, dan juga kemungkinan duplikasi data yang tidak terdeteksi akibat perbrdaan spasi atau tanda baca kecil.

4.2 Pipeline Cleaning Dataset Job

Pipeline cleaning untuk dataset ini ada pada notebook `pipeline_job_data_cleaning.ipynb` (dapat diakses pada tautan berikut https://github.com/ITCareerMatch/Data-Science-ITCareerMatch/blob/main/notebook/pipeline_job_data_cleaning.ipynb) dengan hasil data clean `dataset_job.xlsx` dan `glints_job.xlsx` (dapat diakses melalui tautan berikut https://github.com/ITCareerMatch/Data-Science-ITCareerMatch/tree/main/dataset_clean).

Alur pipeline cleaning secara detail terdiri dari beberapa tahapan berikut:

4.2.1 Pembacaan Dataset

Dataset hasil scaing web Glints dibaca via glob, sehingga tidak perlu mendaftarkan nama file satu per satu. Seluruh file kemudian digabung dengan `pd.concat(ignore_index=True)`.

```

FOLDER_SCRAPING = r'..\dataset_mentah\data_job_scraping'
all_files_scraping =
glob.glob(os.path.join(FOLDER_SCRAPING, '*.xlsx'))

```

```

df_list_scraping = []
for filepath in all_files_scraping:
    _df = pd.read_excel(filepath)
    df_list_scraping.append(_df)

```



```
df_scraping = pd.concat(df_list_scraping,
ignore_index=True)
```

Kemudian untuk beberapa dataset job yang berasal dari kaggle dibaca satu persatu ke dictionary dictionary dataframes_kaggle menggunakan nama file sebagai key, sehingga mudah diakses saat proses mapping kolom di langkah berikutnya.

```
file_names_kaggle = [
    'IT_Job_Roles_Skills.xlsx', 'Job
opportunities.xlsx',
    'job_titles_and_descriptions.xlsx', 'jobs.xlsx',
    'JobsDatasetProcessed.xlsx', 'postings.xlsx',
    'Scrapped_data.xlsx'
]

dataframes_kaggle = {}
for file in file_names_kaggle:
    file_path = os.path.join(FOLDER_KAGGLE, file)
    dataframes_kaggle[file] = pd.read_excel(file_path)
```

4.2.2 Mapping Kolom

Tujuh file Kaggle memiliki nama kolom berbeda untuk konsep yang sama. Tanpa mapping eksplisit, `pd.concat()` akan menghasilkan 20+ kolom dengan sebagian besar berisi NaN. `column_mapping` mendefinisikan mapping dari nama kolom asli ke nama kolom standar. Kolom yang tidak tersedia di suatu file diisi `pd.NA` otomatis agar struktur tetap konsisten.

```
column_mapping = {
    'IT_Job_Roles_Skills.xlsx' : {'Job Title':
'posisi', 'skill': 'skill', 'Job Description':
'kualifikasi'},
    'Job opportunities.xlsx' : {'Job Title':
'posisi', 'Required Skills': 'skill',
'Experience
Level': 'pengalaman', 'Job Description': 'kualifikasi'},
    'job_titles_and_descriptions.xlsx': {'Job Title':
'posisi', 'Skills': 'skill', 'Job Description':
'kualifikasi'},
    'jobs.xlsx' : {'Job_title':
'posisi', 'skills_required': 'skill'},
```

```

        'JobsDatasetProcessed.xlsx'          : {'Job Title':
'posisi', 'IT Skills': 'skill',
                                                'Education':
'pendidikan', 'Experience': 'pengalaman', 'Description':
'kualifikasi'},
        'postings.xlsx'                     : {'job_title':
'posisi', 'job_skills': 'skill',
                                                'job level':
'pengalaman', 'job_summary': 'kualifikasi'},
        'Scrapped_data.xlsx'                : {'Job Name':
'posisi', 'Skills': 'skill',
                                                'YOE':
'pengalaman', 'JD': 'kualifikasi'},
    }

target_columns_ai = ['posisi', 'pendidikan',
'pengalaman', 'gender', 'usia', 'skill', 'kualifikasi']

# Setiap file dipetakan, kolom target yang tidak ada
diisi pd.NA
for col in target_columns_ai:
    if col not in df_kaggle.columns:
        df_kaggle[col] = pd.NA

```

4.2.3 Cleaning Dataset Scraping (Dataset untuk DB Fullstack)

Dataset scraping dipersiapkan sebagai Full Data (FD) yang ditampilkan langsung ke pengguna platform, sehingga standar kualitasnya lebih ketat. Proses cleaning berjalan lima langkah berurutan sesuai notebook:

Tabel 10. Alur Cleaning Hasil Data Scraping

Langkah	Kode	Alasan
1. Cek nilai kosong	df_scraping.isnull().sum()	Identifikasi kolom mana yang perlu penanganan sebelum transformasi apapun

Langkah	Kode	Alasan
2. Drop baris tanpa tautan	<code>dropna(subset=['tautan'])</code>	tautan adalah primary key, data tanpa key tidak bisa diarahkan ke Glints
3. Isi kolom opsional	<code>fillna()</code> dengan nilai default deskriptif	Mencegah NaN masuk ke tampilan platform; nilai default lebih informatif dari string kosong
4. Hapus duplikat	<code>drop_duplicates(subset=['perusahaan', 'posisi'])</code>	Satu perusahaan tidak seharusnya punya dua lowongan dengan posisi yang sama
5. Normalisasi jenis & kategori	<code>str.split() + str.split('>')</code>	Pisah tipe waktu kerja dari sistem kerja; ekstrak sub-kategori peran yang lebih spesifik

```
# Langkah 3 – isi nilai kosong kolom opsional
df_scraping['gaji'] =
df_scraping['gaji'].fillna('perusahaan tidak menampilkan gaji')
df_scraping['gender'] =
df_scraping['gender'].fillna('tanpa ketentuan')
df_scraping['usia'] =
df_scraping['usia'].fillna('tanpa batasan usia')
df_scraping['pengalaman'] =
df_scraping['pengalaman'].fillna('tidak ada')
```

```

df_scraping['pendidikan'] =
df_scraping['pendidikan'].fillna('terbuka untuk semua
jenjang dan jurusan')

# Langkah 4 – hapus duplikat
df_scraping.drop_duplicates(subset=['perusahaan',
'posisi'], inplace=True)
df_scraping.reset_index(drop=True, inplace=True)

# Langkah 5 – pisah jenis_pekerjaan dan ekstrak
kategori_peran
df_scraping[['tipe_waktu_kerja', 'sistem_kerja']] = (

df_scraping['jenis_pekerjaan'].str.split(r'\s*[\.] \s*',
n=1, expand=True)
)
df_scraping['kategori_peran'] =
df_scraping['kategori'].str.split(r'\s*>\s*', n=1,
expand=True)[1]

```

4.2.4 Cleaning Dataset Kaggle (AI Training Data)

Dataset Kaggle dipersiapkan sebagai data training AI. Sebelum cleaning, kolom relevan dari df_scraping yang sudah bersih digabungkan ke df_kaggle agar data riil Glints juga ikut melatih model.

```

# Gabungkan data scraping bersih ke df_kaggle
KOLOM_AI = ['posisi', 'pendidikan', 'pengalaman',
'gender', 'usia', 'skill', 'kualifikasi']
df_scraping_ai = df_scraping[KOLOM_AI].copy()
df_kaggle = pd.concat([df_kaggle, df_scraping_ai],
ignore_index=True)

```

Tabel 11. Alur Cleaning Data Job Kaggle

Langkah	Kode	Alasan
Drop baris tanpa posisi/skill	dropna(subset=['posisi', 'skill'])	posisi dan skill adalah fitur inti model, baris tanpa keduanya tidak berguna

Langkah	Kode	Alasan
Isi kolom opsional	<code>fillna()</code> dengan nilai default	Konsistensi struktur; model memerlukan nilai di setiap kolom
Hapus duplikat AI	<code>drop_duplicates(subset=['posisi', 'skill'], keep='first')</code>	Pasangan posisi-skill identik tidak menambah informasi baru untuk training

```
df_ai = df_kaggle.copy()
df_ai.dropna(subset=['posisi', 'skill'], inplace=True)

fill_values_ai = {
    'gender': 'tanpa ketentuan', 'usia': 'tanpa batasan usia',
    'pengalaman': 'tidak ada', 'pendidikan': 'terbuka untuk semua jenjang dan jurusan'
}
df_ai.fillna(value=fill_values_ai, inplace=True)

df_ai.drop_duplicates(subset=['posisi', 'skill'], keep='first', inplace=True)
df_ai.reset_index(drop=True, inplace=True)
```

4.2.5 Standarisasi Kolom Pendidikan

Fungsi `standardize_pendidikan()` memetakan variasi teks multibahasa ke delapan label standar menggunakan *keyword matching case-insensitive*. Hierarki pencocokan berjalan dari level tertinggi (PhD) ke terendah, mencegah false match di mana teks seperti 'Master who studied bachelor' salah dikategorikan sebagai Sarjana.

Tabel 12. Klafisikasi Label Standarisasi Pendidikan

Label Standar	Contoh Kata Kunci yang Dipetakan (ID + EN)
Doktoral (S3)	phd, ph.d, doktor, doctoral, s3, doctor of philosophy

Label Standar	Contoh Kata Kunci yang Dipetakan (ID + EN)
Magister (S2)	master, magister, s2, mba, postgraduate, graduate degree, m.sc, m.eng
Sarjana (S1)	bachelor, sarjana, s1, undergraduate, b.s, college degree, b.tech, degree in
Diploma IV (D4)	d4, d-4, diploma iv, diploma 4
Diploma III (D3)	d3, d-3, diploma iii, associate degree
Diploma I/II	d1, d2, diploma i, diploma ii
SMA/SMK	sma, smk, high school, secondary school, ged, vocational school
SMP/SD	smp, middle school, junior high, sd
Default	→ 'terbuka untuk semua jenjang dan jurusan'

4.2.6 Standarisasi Kolom Pengalaman

Fungsi `standardize_pengalaman()` menggunakan empat strategi pencocokan berurutan (*cascading pattern matching*). Strategi dijalankan dari yang paling spesifik ke yang paling umum:

Tabel 13. Klasifikasi Standarisasi Pengalaman

Prioritas	Strategi	Contoh Input → Output
1	Level keyword — 'Junior', 'Senior', 'Entry-Level', 'Internship'	'Senior Developer' → '5+ tahun'
2	Range pattern — pola 'X-Y years' atau 'X-Y tahun'	'3-5 years experience' → '3-5 tahun'
3	Plus pattern — pola 'X+ years'	'5+ years' → '5+ tahun'
4	Single pattern — pola 'X years'	'2 years' → '2 tahun'
5	Tidak ada pola yang cocok	Teks apapun → 'tidak ada'

4.2.7 Standarisasi Skill via Kamus IT

Normalisasi token skill dilakukan menggunakan kamus `Kamus_IT_Bersih_Filtered.csv`. Fungsi `process_skill()` menjalankan enam langkah berurutan per nilai kolom skill:

1. Handle null, kembalikan string kosong untuk NaN/None agar tidak error di langkah berikutnya.
2. Bersihkan noise, hapus karakter seperti *"'()[]{}#@! via compiled regex.
3. Tokenisasi, pisah string menjadi list token berdasarkan koma (`str.split(',')`).
4. Standarisasi token, cocokkan tiap token ke kamus (case-insensitive). Jika tidak ada, kembalikan aslinya, tidak ada data yang hilang.
5. Hapus duplikat, `dict.fromkeys()` mempertahankan urutan kemunculan pertama.
6. Gabung kembali, `', '.join(tokens)` untuk kompatibilitas dengan kolom lain.

4.2.8 Enrichment Kolom Kualifikasi via Groq API

Kolom kualifikasi dari berbagai sumber sangat beragam, ada yang berisi satu kata ('Analytical'), ada paragraf panjang, ada yang kosong. Untuk memungkinkan perbandingan yang fair, semua lowongan perlu direpresentasikan dalam format naratif yang konsisten. Teknik *LLM-based data augmentation* digunakan untuk tujuan ini.

Prompt perintah LLM Prompt dirancang dengan menyertakan lima konteks per baris untuk menghasilkan output yang spesifik pada domain:

Instruksi sistem:

Tulis SATU kalimat kualifikasi teknis dengan struktur wajib:

[skill teknis spesifik] + [lama & bidang pengalaman] + [tugas utama]

Gunakan kata kerja aktif: menguasai, mampu, berpengalaman.

Bahasa Indonesia. Tanpa bullet. Tanpa enter. Langsung ke inti.

Konteks yang disertakan:

```
posisi      : {posisi[:100]}
skill       : {skill[:200]}
pengalaman: {pengalaman[:80]}
pendidikan: {pendidikan[:80]}
kualifikasi asli: {kualifikasi[:300]}
```

Strategi batch processing dan juga checkpoint juga diterapkan pada pipeline cleaning dataset job. Proses enrichment dapat memakan waktu berjam-jam untuk

11.000+ baris. Sistem checkpoint diimplementasikan agar pipeline dapat dilanjutkan dari titik terakhir tanpa mengulang dari awal jika terjadi interupsi.

```
# Load checkpoint → hitung done_indices
if os.path.exists(CHECKPOINT_FILE):
    ckpt = pd.read_csv(CHECKPOINT_FILE)
    ckpt = ckpt.drop_duplicates(subset='original_index',
                              keep='last')
    done_indices =
set(ckpt['original_index'].astype(int).tolist())

# Loop hanya pada baris yang belum diproses
pending = [idx for idx in df.index if idx not in
done_indices]

# Simpan otomatis setiap BATCH_SIZE baris
if len(new_rows) % BATCH_SIZE == 0:
    _save_checkpoint(new_rows, CHECKPOINT_FILE)
```

4.2.9 Deduplikasi Dataset Job

Dataset job dari berbagai sumber berpotensi mengandung baris yang mirip. Deduplikasi dilakukan berdasarkan kombinasi posisi + skill, dua baris dengan jabatan dan daftar skill yang identik dianggap duplikat dan salah satu dihapus. Ini mencegah bias pada model akibat pengulangan data identik.

BAB 5

HASIL AKHIR DATASET & EDA

5.1 Dataset Bersih

Setelah melalui rangkaian proses *data cleaning*, normalisasi, dan validasi manual, diperoleh dataset akhir yang siap digunakan untuk tahapan analisis lebih lanjut. Dataset ini merupakan representasi data yang telah terstruktur, bebas dari duplikasi, dan memiliki konsistensi format yang diperlukan untuk mendukung akurasi sistem *matching*. Rincian akhir dari dataset yang telah dibersihkan dapat dilihat pada tabel berikut:

Tabel 14. Detail Hasil Akhir Dataset/Data Bersih


No	Nama Dataset	Jumlah Baris	Jumlah Kolom	Deskripsi Singkat
1	dataset_cv	11.915	4	Dataset CV kandidat yang berisi pendidikan, pengalaman, skill, dan ringkasan profil kandidat. Digunakan sebagai sisi kandidat dalam sistem job-CV matching.
2	dataset_job	11.027	9	Dataset lowongan kerja gabungan yang berisi persyaratan posisi yang sudah dinormalisasi. Digunakan sebagai dataset utama untuk sisi job dalam sistem matching.
3	glints_job	565	14	Dataset job dari Glints dengan data paling lengkap (termasuk URL, perusahaan, gaji, sistem kerja). Digunakan untuk basis data fullstack dan sebagai data asli dan direct ke platform glints.

5.2 Exploratory Data Analysis (EDA)

Pada subbab ini disajikan analisis data eksploratif untuk mengekstraksi wawasan berharga dari dataset yang telah disiapkan. Proses eksplorasi dilakukan dengan menjawab 10 pertanyaan bisnis utama yang disusun menggunakan metode SMART (*Specific, Measurable, Achievable, Relevant, Time-bound*). Analisis ini bertujuan untuk memetakan tren kualifikasi pasar kerja IT serta perilaku rekrutmen di Indonesia melalui visualisasi data.

- **BQ 1** : Bagaimana distribusi tingkat pendidikan kandidat dalam dataset_cv, dan apakah S1 mendominasi lebih dari 50% dari total kandidat?


Jawaban:



Gambar 1. Visualisasi Business Question 1

- **BQ 2** : Dari seluruh lowongan di dataset_job, berapa persen yang menargetkan kandidat entry-level (0–2 tahun) dibandingkan mid-level (2–5 tahun) dan senior (5+ tahun), kemudian apakah entry-level mendominasi lebih dari 40% dari total lowongan?

Jawaban:




Gambar 2. Visualisasi Business Question 2

Ya, Entry-level mendominasi >40% (sebesar 52.95%)

- **BQ 3:** Dari 565 lowongan di glints_job, kota mana yang masuk top 5 terbanyak, dan bagaimana komposisi sistem kerja (WFO/WFH/Hybrid) di masing-masing kota tersebut?


Jawaban:



Gambar 3. Visualisasi Business Question 3

- **BQ 4 :** Dari kategori peran di glints_job yang memiliki minimal 5 lowongan, mana 10 peran dengan median gaji tertinggi dan terendah (diluar perusahaan yang tidak menampilkan gaji), dan seberapa lebar rentang gajinya?

Jawaban:




Gambar 4. Visualisasi Business Question 4

Lowongan dengan median gaji tertinggi : Product Manager (Rp 10.00 Jt)

Lowongan dengan median gaji terendah : Technical Support Engineer (Rp 3.50 Jt)
Rentang gaji: Rp 6.50 Jt

- **BQ 5** : Bagaimana perbandingan distribusi tingkat pendidikan antara kandidat (dataset_cv) dan syarat minimum lowongan (dataset_job) secara berdampingan per level pendidikan serta di level mana selisih persentase antara keduanya paling besar (>15 poin)?

Jawaban:




Gambar 5. Visualisasi Business Question 5

Gap terbesar ada pada Magister (S2) (77.6 poin)

Ada gap >15 poin? Ya

- **BQ 6** : Dari seluruh lowongan di Glints_job, apa 15 skill yang paling sering muncul di kolom skill (dihitung setelah split koma), dan apakah ada 1 skill yang muncul di lebih dari 30% total lowongan sehingga bisa disebut skill dominan pasar IT?

Jawaban:



Gambar 6. Visualisasi Business Question 6


Top skill yang paling sering muncul adalah "MySQL" (15.58%)

Tidak ada skill yang muncul >30% di semua lowongan.

- **BQ 7** : Dari kandidat di Dataset_cv, berapa rata-rata jumlah skill per bucket pengalaman, dan apakah kandidat senior (5+ tahun) memiliki rata-rata skill minimal 2x lebih banyak

dibanding (dihitung dari jumlah skill per baris setelah split koma di kolom skill) entry-level (0–1 tahun)?

Jawaban:




Gambar 7. Visualisasi Business Question 7

Senior $\geq 2 \times$ skill dari entry? Tidak

Rasionya : $1.54 \times$ (Entry: 14.15, Senior: 21.78)

- BQ 8 :** Dari 45 kategori peran di glints_job, apakah tipe waktu kerja Penuh Waktu mendominasi lebih dari 70% di setiap kategori, atau ada kategori tertentu yang justru didominasi Magang/Freelance/Kontrak?

Jawaban:




Gambar 8. Visualisasi Business Question 8

Penuh Waktu $> 70\%$ di semua kategori? Tidak (ada 19 kategori yang tidak memenuhi)

- **BQ 9 :** Dari seluruh lowongan di dataset_job, berapa persen yang masih mencantumkan persyaratan gender atau usia spesifik, dan posisi apa yang paling sering membatasinya, serta apakah total lowongan yang membatasi melebihi 20% dari keseluruhan?

Jawaban:





Gambar 9. Visualisasi Business Question 9

2.06% lowongan memiliki batasan gender/usia
Melebihi 20% keseluruhan? Tidak

- **BQ 10 :** Dari 10 kategori peran terbanyak di glints_job, bagaimana perbandingan median gaji antara lowongan WFO, WFH, dan Hybrid?:

Jawaban:





Gambar 10. Visualisasi Business Question 10

Sistem kerja gaji tertinggi: "Hybrid" (Rp 8.00 Jt)

BAB 6

KESIMPULAN

6.1 Pencapaian Teknis

Proyek ITCareerMatch telah berhasil menyusun fondasi data untuk sistem *job-CV matching* di sektor IT Indonesia melalui lima tahapan teknis utama. Setiap tahapan dirancang untuk memastikan data yang diproses tidak hanya akurat, tetapi juga memiliki skalabilitas tinggi untuk menangani variasi format dokumen dunia nyata. Ringkasan dari pencapaian teknis tersebut disajikan pada tabel berikut:

Tabel 15. Ringkasan Pencapaian Teknis Data

Pencapaian	Detail	Dampak
Pipeline OCR Adaptif	Deteksi otomatis PDF teks-based vs image-based via threshold 30 char/halaman	+30% CV dunia nyata dalam format scan dapat diproses tanpa konfigurasi manual
Normalisasi Skill Berbasis Kamus	Regex terpanjang ke terpendek mengstandarkan ratusan variasi penulisan	Menghilangkan fragmentasi skill sebagai sumber kegagalan keyword-matching
LLM-Assisted Data Enrichment	LLaMA-3.1-8B via Groq mengisi kolom detail dan kualifikasi dari teks tidak terstruktur	Tingkat pengisian kualifikasi >99,9%
Sistem Checkpoint Robust	Double drop_duplicates, progress tracking berbasis index aktual, konvensi nama file	Pipeline multi-sesi tanpa kehilangan data, aman diulang kapan saja
Dataset Representatif	22.942 baris total (11.915 CV + 11.027 Job) + 565 data Glints sebagai ground truth	Cakupan skill IT luas dengan referensi pasar Indonesia aktual

6.2 Keterbatasan yang Teridentifikasi

Selama proses pengembangan, ditemukan beberapa batasan teknis pada dataset yang memengaruhi akurasi sistem secara keseluruhan. Keterbatasan tersebut, beserta dampak dan tingkat risikonya, dirangkum dalam tabel berikut:

Tabel 16. Ringkasan Keterbatasan Teknis Data

Keterbatasan	Dampak	Risiko
Kolom pengalaman Dataset_job masih +-106 variasi	Matching pengalaman tidak dapat dilakukan secara langsung	Sedang
Format pendidikan Glints ada prefix 'Minimal'	Perlu preprocessing tambahan sebelum matching	Rendah
857 null di kolom detail CV (7,2%)	Kandidat ini tidak dapat di-match via narasi semantik, hanya via skill	Rendah-Sedang
Data Glints hanya 565 baris	Representasi pasar Indonesia masih terbatas untuk validasi model	Sedang
Kamus skill belum mencakup soft skills	Matching untuk posisi manajerial kurang optimal	Rendah

BAB 7

REKOMENDASI & ACTION ITEMS

Berdasarkan hasil analisis dan evaluasi dataset yang telah dilakukan, berikut adalah daftar langkah yang perlu segera diimplementasikan untuk mengoptimalkan kinerja sistem *matching*.

7.1 Prioritas Tinggi

1. Normalisasi Kolom Pengalaman di dataset `_job`

Masalah: +-106 variasi format pengalaman di Dataset `_job` belum seragam, menyebabkan matching experience level tidak dapat dilakukan langsung.

```
def normalize_job_experience(raw: str) -> str:
    """Normalkan format pengalaman job ke 7 kategori
    standar."""
    years = _extract_years_explicit(raw) or
    _extract_years_from_dates(raw)
    return _categorize_experience(years)

df_job['pengalaman_norm'] =
df_job['pengalaman'].apply(normalize_job_experience)
```

Target: Kolom pengalaman di semua dataset menggunakan 7 kategori yang sama.

2. Normalisasi Format Pendidikan glints `_job`

Masalah: Glints menggunakan prefix 'Minimal' yang perlu di-strip sebelum matching.

```
df_glints['pendidikan'] =
df_glints['pendidikan'].str.replace(r'^Minimal\s+', '',
regex=True)
```

3. Ekspansi Kamis Skill IT

Masalah: Teknologi baru (LangChain, RAG, Rust, Bun.js) muncul terus-menerus dan perlu dimasukkan ke kamus secara berkala.

- Review kamus setiap 3 bulan , tambahkan skill yang muncul $\geq 10\times$ di data baru sebagai entri resmi.

7.2 Prioritas Sedang

1. Penambahan Volume Data Glints

Menjadwalkan scraping ulang setiap 2 minggu menggunakan rotating proxy untuk menghindari pemblokiran.

2. Validasi Output LLM

Output LLM terkadang tidak sesuai/tidak informatif, solusinya adalah melakukan random sampling 100 baris dari masing-masing dataset untuk human review.

7.3 Prioritas Jangka Panjang

1. Integrasi Real-Time dengan Platform Job

Data statis dari Kaggle akan kadaluarsa seiring waktu, Kemudian job hasil scraping pun tidak terbuka untuk dalam rentang waktu lama, Integrasi API atau scraping terjadwal dengan Glints dan platform lain (Jobstreet, LinkedIn) akan memastikan sistem tetap relevan dengan kondisi pasar terkini. [8]

REFERENSI

- [1] Google, Temasek & Bain & Company. *"e-Conomy SEA 2024: From Boom to Bedrock."* e-Conomy SEA Annual Report, 2024. https://services.google.com/fh/files/misc/e_conomy_sea_2024_report.pdf
- [2] Gayatri, G., Jaya, I. G. N. M. & Rumata, V. M.. *"The Indonesian Digital Workforce Gaps in 2021–2025."* Sustainability (MDPI), Vol. 15, No. 1, Art. 754. DOI: 10.3390/su15010754, 2022. <https://www.mdpi.com/2071-1050/15/1/754>
- [3] Azzahra, A., Savandha, S. D., Bharoto, R. M. H. & Kevin, N. H.. *"The Impact of High Job Qualification Standards on Unemployment Rates Among Fresh Graduates in Indonesia."* Journal Transnational Universal Studies (JTUS), Vol. 2, No. 4, 2024. <https://journaltransnationaluniversalstudies.org/index.php/gp/article/view/109>
- [4] Populix & KitaLulus, dikutip oleh ANTARA. *"Qualification, Skills Mismatch Ailing Job Market, Says Study."* ANTARA News, 2024. <https://en.antaranews.com/news/323543/qualification-skills-mismatch-ailing-job-market-says-study>
- [5] Glez-Peña, D. et al.. *"Web scraping technologies in an API world."* Briefings in Bioinformatics, Vol. 15, No. 5, pp. 788–797. DOI: 10.1093/bib/bbt026, 2013. <https://doi.org/10.1093/bib/bbt026>
- [6] Batista, G. & Monard, M. C.. *"An Analysis of Four Missing Data Treatment Methods for Supervised Learning."* Applied Artificial Intelligence, Vol. 17, No. 5–6, pp. 519–533. DOI: 10.1080/08839510390219070, 2003. <https://doi.org/10.1080/08839510390219070>
- [7] Banko, M. & Brill, E.. *"Scaling to Very Very Large Corpora for Natural Language Disambiguation."* Proceedings of ACL 2001, pp. 26–33. DOI: 10.3115/1073012.1073017, 2001. <https://dl.acm.org/doi/10.3115/1073012.1073017>
- [8] SMERU Research Institute. *"Digital Upskilling for Indonesia — Policy Paper."* SMERU Research Institute, 2023. <https://smeru.or.id/en/research/digital-upskilling-indonesia>

LAMPIRAN

Github Data Scientist ITCareerMatch:

<https://github.com/ITCareerMatch/Data-Science-ITCareerMatch/tree/main>